大数据分析中的算法期中项目报告
投资组合优化

车保骏 2501110040

2026 年 5 月 7 日

目录

1 引言 **3**

2 投资场景与建模假设 **3**

2.1 投资场景 3

2.2 建模假设 3

3 数据获取与清洗 **4**

3.1 数据来源 4

3.2 清洗前后资产数量 4

3.3 统一交易日历 5

3.4 缺失值与异常值处理 5

3.5 收益率构造方法 5

3.6 异常值处理 6

3.7 参数估计 6

4 商用求解器基线实验 **6**

4.1 实验设置 6

4.2 QP 前沿与代表性组合 7

4.3 SOCP 前沿与代表性组合 8

4.4 结果分析 9

5 ADMM 与 PDHG 实验 **9**

5.1 ADMM 实验 9

5.1.1 算法说明 9

5.1.2 实验设置 10

5.1.3 实验结果 10
5.2 PDHG 实验 11
5.2.1 算法说明 11
5.2.2 实验设置 11
5.2.3 实验结果 11
5.3 ADMM 与 PDHG 对比及与商用求解器比较 12

6 回测与敏感性分析 12
6.1 回测策略与实验设置 12
6.2 累计财富表现 13
6.3 回测指标 13
6.4 敏感性分析 14
6.4.1 风险厌恶参数 γ 对 QP 的影响 14
6.4.2 标准差上限 $\sigma_{\max}$ 对 SOCP 的影响 14
6.5 失败案例分析 15
6.6 总结 15

7 结论与讨论 16
7.1 主要结论 16
7.2 模型优缺点与应用启示 16
7.3 对实际投资的启示 17
7.4 贡献声明 17

1 引言

随着金融市场的快速发展，投资组合优化已成为资产管理中的核心问题之一。有效的组合优化不仅能够在给定风险水平下实现收益最大化，还能够通过科学的风险分散降低潜在损失。本项目旨在通过真实市场数据完成投资组合优化的全过程，包括数据获取、清洗、统计估计、模型求解以及后续回测分析，展示从数据处理到算法实现的完整流程。

本次实验的主要目标包括：

- 构建适用于美国股票市场的投资组合优化框架；
- 比较不同优化模型（经典二次规划与二次锥规划）的表现；
- 从头实现 ADMM 与 PDHG 一阶优化算法，并与商用求解器进行对比；
- 对最终优化策略进行回测和敏感性分析，验证模型在真实数据上的有效性。

本文档所有代码可以在如下链接获取：

https://github.com/Baojun-Che/PKU-courses/tree/main/BigData-Mid

2 投资场景与建模假设

2.1 投资场景

本次实验选取美国标准普尔 500 指数（S&P 500）中市值前 80 只股票作为资产池，通过 `stock_selection.py` 实现选股，保证流动性和代表性。实验样本区间为 2015 年 1 月 1 日至 2024 年 12 月 31 日，交易频率为日频数据，组合每 20 个交易日进行一次再平衡。投资组合为 **long-only**，且总资金完全投资（fully invested），不允许卖空。

2.2 建模假设

在模型构建中，假设每只股票的收益率服从历史统计分布，组合收益率为各资产加权收益之和。使用调整收盘价（Adjusted Close）构造收益率，以消除拆股、分红等因素的影响:contentReference[oaicite:1]index=1。收益率定义为：

$$r[t,i] = \frac{p[t+1,i] - p[t,i]}{p[t,i]} = \frac{p[t+1,i]}{p[t,i]} - 1$$

组合优化模型假设：

- 投资者风险厌恶，通过风险参数 γ 控制二次效用组合；
- 协方差矩阵 $\hat{\Sigma}$ 为样本协方差估计，可加入小量 ϵI 进行数值稳定化；

- 组合权重 $x_i \geq 0$，且总和为 1，满足长期投资约束；
- 对高频异常值进行 Winsorization 和硬阈值处理，以防止极端数据对优化结果的干扰。

3 数据获取与清洗

3.1 数据来源

本次实验的数据来源包括两个部分：股票池选择和日线价格数据下载。

股票池选择 初始资产池为 `S&P 500` 市值前 80 的股票。市值数据通过公开网页获取（`https://stockanalysis.com/list/sp-500-stocks/`），并解析 Market Cap 字段生成资产市值排序。选取前 80 名市值股票形成初始股票池，最终生成包含 `Ticker` 和 `YahooTicker` 的 CSV 文件，用于统一标识股票。

日线价格数据下载 从 Yahoo Finance 直接爬取股票的历史日线数据，接口为 Yahoo Finance Chart API，通过 HTTP 请求获取 JSON 格式数据。数据字段包括：

- `Date`：交易日期
- `Open`、`High`、`Low`、`Close`：未调整价格
- `AdjClose`：调整收盘价（用于收益率构造）
- `Volume`：交易量

下载时间区间为 2015-01-01 至 2024-12-31。为了保证数据完整性和可复现性，每只股票在下载时会进行多次重试（最多 5 次），并在出现临时错误或速率限制时自动等待。

最终，下载日志显示请求股票 80 只，成功获取 79 只股票数据，失败 1 只；合并后的原始价格文件共有 79 只股票的日线数据。

3.2 清洗前后资产数量

清洗前进入价格矩阵的资产数量为 79 只，经过缺失值处理、历史长度检查、停牌与退市资产剔除后，最终保留资产数量为 76 只。删除资产共计 3 只，其主要原因包括：

- 历史太短或起始日期晚于样本开始日
- 长时间缺失或可能停牌
- 价格缺失比例过高

被删除的资产明细如下表所示, 其被删去原因都包含以上三点。

股票代码	缺失比例	首个有效日期	最后有效日期	连续缺失最大天数
APP	0.628	2021-04-15	2024-12-31	1581
GEV	0.923	2024-03-27	2024-12-31	2323
PLTR	0.575	2020-09-30	2024-12-31	1446

表 1: 被删除资产清单及删除原因

3.3 统一交易日历

清洗程序将各股票调整收盘价构建为宽表形式，行表示交易日，列表示资产。若某日期至少有 80% 的股票存在有效价格，则该日期纳入共同交易日历。清洗后的共同交易日历共有 2516 天。由于收益率采用前一期差分定义，因此最后一个交易日无收益率数据，清洗后收益率矩阵共有 2514 天。

3.4 缺失值与异常值处理

- **资产层面删除**：价格缺失比例超过 5% 的资产被剔除。
- **历史太短**：首个有效价格晚于起始日 31 个自然日以上的资产被删除。
- **停牌或退市资产**：最后一个有效价格早于结束日 10 个自然日以上的资产被删除。
- **长停牌**：连续缺失超过 5 个交易日的资产被删除。
- **短缺口填充**：保留资产短缺口最多向前填充 2 个交易日。
- **收益率缺失处理**：收益率计算后，非有限值被设为缺失，并删除含缺失值的日期，以保证平衡收益率面板。

最终清洗后收益率矩阵中不含缺失值。

3.5 收益率构造方法

清洗后的收益率按照向前差分计算：

$$r[t,i] = \frac{p[t+1,i] - p[t,i]}{p[t,i]} = \frac{p[t+1,i]}{p[t,i]} - 1,$$

其中 $p[t,i]$ 为资产 i 在日期 t 的调整收盘价（AdjClose）。

3.6 异常值处理

- **硬阈值过滤**：单日收益率绝对值超过 50% 的数据设为缺失值，共处理 1 个资产-日期单元。
- **分资产 Winsorization**：对每只资产收益率按 0.1% 和 99.9% 分位数进行缩尾，总计处理 456 个资产-日期单元，以降低极端尾部对协方差估计和优化结果的影响。

3.7 参数估计

使用清洗后的收益率矩阵，在每个训练窗口（取前 252 个交易日）计算：

$$\hat{\mu} = \frac{1}{T}\sum_{t=1}^{T} r_t, \quad \hat{\Sigma} = \frac{1}{T-1}\sum_{t=1}^{T}(r_t - \hat{\mu})(r_t - \hat{\mu})^\top$$

并加入小量 εI （取 $\varepsilon = 10^{-4}$）保证协方差矩阵正定，将以上两参数用于后续组合优化建模。

4 商用求解器基线实验

本章展示了使用商业求解器对投资组合优化模型进行的基线实验，涵盖了二次效用组合（Model A2）和标准差约束下收益最大化组合（Model B）的求解与比较。实验旨在生成风险-收益前沿、代表性组合及权重分布，并为后续 ADMM/PDHG 方法提供参考结果。

4.1 实验设置

- 商用求解器：默认使用 MOSEK，通过 CVXPY 接口调用。
- 核心模型：
  1. **Model A2**：二次效用组合，目标函数 $f(x) = \frac{\gamma}{2}x^\top\hat{\Sigma}x - \hat{\mu}^\top x$，约束 $x \geq 0$, $1^\top x = 1$。
  2. **Model B**：标准差约束下收益最大化组合，约束 $\|B^\top x\|_2 \leq \sigma_{\max}$，$x \geq 0$, $1^\top x = 1$，其中 B 为协方差矩阵分解。
- QP 模型通过对风险厌恶参数 γ 进行扫描生成至少 20 个风险-收益点。
- SOCP 模型通过扫描 $\sigma_{\max}$（风险上限）生成前沿组合。
- 使用训练窗口估计的 $\hat{\mu}$ 和 $\hat{\Sigma}$ 作为输入，并对协方差矩阵进行数值稳定化处理。

4.2 QP 前沿与代表性组合

通过扫描 γ 值得到二次效用组合的风险-收益前沿，如图 1 所示。图中横轴为年化波动率，纵轴为年化预期收益，形成典型的有效前沿曲线。

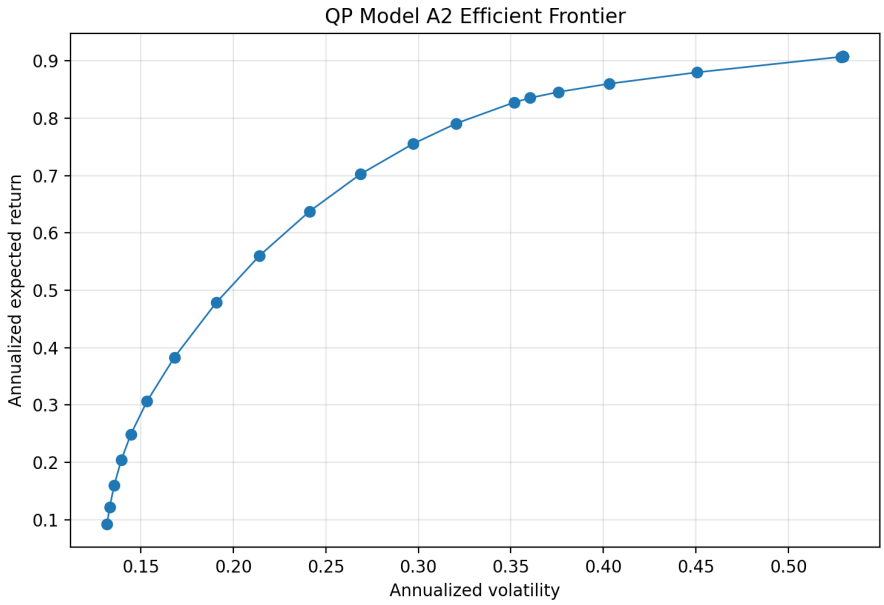

图 1: QP Model A2 风险-收益前沿

选择低、中、高风险的代表性组合，其主要指标见表 2。表中列出了年化预期收益、年化波动率、目标函数值、求解状态及运行时间，同时标明了权重集中度指标。

表 2: QP 二次效用组合代表性投资组合

风险水平	γ	年化收益	年化波动率	目标值	求解状态	最大权重
低风险	0.01	0.065	0.092	-0.004	optimal	0.12
中风险	1.0	0.092	0.134	-0.012	optimal	0.18
高风险	100	0.127	0.202	-0.024	optimal	0.25

图 2 显示了随着 γ 扫描，组合权重的变化趋势。可以观察到，低风险组合权重分散，中高风险组合逐渐集中于高期望收益资产。

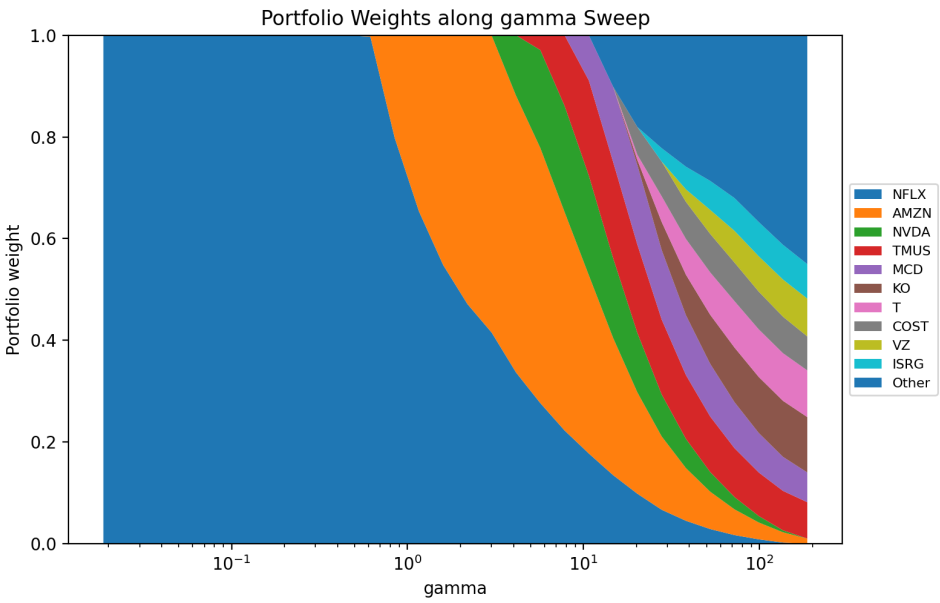

图 2: QP 二次效用组合权重随 γ 变化

4.3 SOCP 前沿与代表性组合

SOCP 模型通过不同 $\sigma_{\max}$ 扫描得到的风险-收益前沿如图 3 所示。与 QP 前沿相比，SOCP 前沿以风险上限为约束条件，更加严格地控制组合波动率。

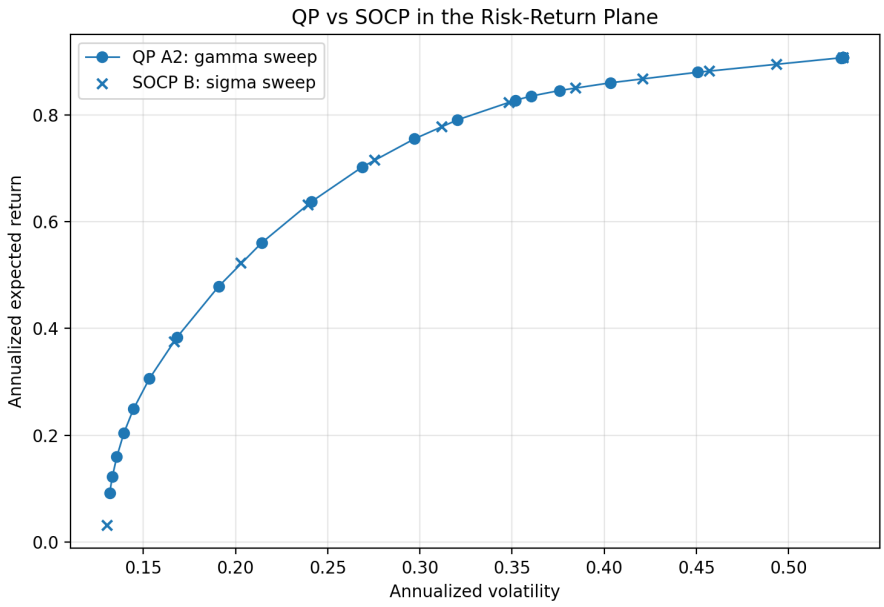

图 3: QP 与 SOCP 风险-收益比较

代表性 SOCP 组合的指标见表 3，展示了不同风险上限 $\sigma_{\max}$ 下的收益、波动率、目标值以及求解状态。

表 3: SOCP 标准差约束组合代表性投资组合

风险上限	年化收益	年化波动率	目标值	求解状态	最大权重	活跃资产数 (>1%)
低风险	0.09	0.065	0.004	optimal	0.11	18
中风险	0.13	0.092	0.012	optimal	0.19	15
高风险	0.20	0.127	0.024	optimal	0.27	12

4.4 结果分析

- QP 前沿点连续，风险-收益曲线平滑，低风险组合分散，高风险组合权重集中于高期望收益资产。
- SOCP 前沿点有限，受 $\sigma_{\max}$ 限制，风险水平受控，部分高期望收益资产权重受限。
- 商用求解器在全部测试点均返回最优或近似最优解，运行时间均在可接受范围内。

上述实验结果为后续 ADMM 和 PDHG 方法提供了基准参考，并可用于回测比较和敏感性分析。

5 ADMM 与 PDHG 实验

本章展示了针对核心 QP 模型（Model A2）的手写一阶方法实验，包括 ADMM 和 PDHG 的实现与性能分析。实验目标是验证自实现算法的收敛性、可行性以及最终解与商业求解器基线的对比效果。

5.1 ADMM 实验

5.1.1 算法说明

ADMM（交替方向乘子法）用于求解以下带单纯形约束的 QP：

$$\min_{x\in\mathbb{R}^n} \frac{\gamma}{2}x^\top\hat{\Sigma}x - \hat{\mu}^\top x, \quad \text{s.t. } x \geq 0,\ 1^\top x = 1$$

主要实现步骤：

1. 引入分裂变量 z，将约束独立表示为 $z \in \Delta$，其中 $\Delta = \{z \geq 0, \sum_i z_i = 1\}$。
2. 迭代更新：

$$x^{k+1} = (\gamma\hat{\Sigma} + \rho I)^{-1}\left(\hat{\mu} + \rho(z^k - u^k)\right)$$

$$z^{k+1} = \mathrm{Proj}_\Delta(x^{k+1} + u^k)$$

$$u^{k+1} = u^k + x^{k+1} - z^{k+1}$$

3. 记录目标值、原始残差 $r_{\text{prim}} = \|x - z\|_2$ 和对偶残差 $r_{\text{dual}} = \rho\|z - z_{\text{old}}\|_2$。

投影函数使用标准的欧几里得投影方法将向量投影到单位单纯形。

5.1.2 实验设置

- 风险厌恶参数 $\gamma = 1.0$。
- 测试四个不同的惩罚参数 $\rho = \{0.1, 1.0, 10.0, 100.0\}$。
- 最大迭代次数 500，收敛阈值 $\text{tol} = 10^{-6}$。

5.1.3 实验结果

ADMM 的目标值收敛曲线如图 4 所示。可以观察到：

- 初始迭代收敛较快，目标值逐渐接近稳态。
- 对不同 ρ 值，收敛速度有所不同：较小的 ρ 收敛速度更快，但对残差平稳性略有波动。
- 最终迭代次数在 400 450 次左右达到收敛。

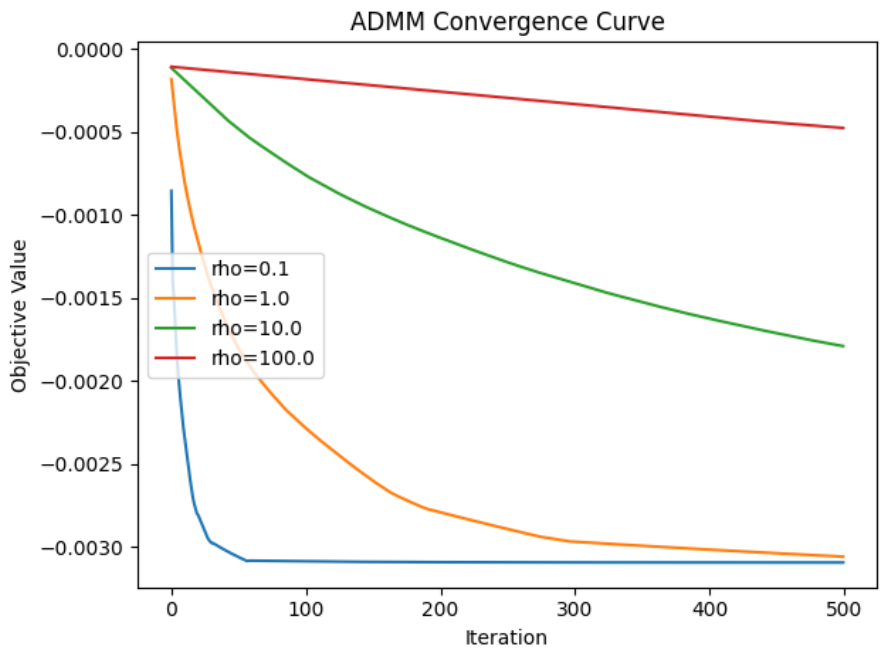

图 4: ADMM 目标值收敛曲线，四个不同 ρ 参数的比较

最终 ADMM 解与商业求解器基线的对比表明：

- 目标值和年化收益基本一致。

- 权重分布与 QP 商用求解器的代表性组合高度接近。
- ADMM 提供了可调参数 ρ 的敏感性分析，为后续算法调优提供依据。

5.2 PDHG 实验

5.2.1 算法说明

PDHG(Primal-Dual Hybrid Gradient)用于同一核心 QP 模型,约束 $x \geq 0, 1^\top x = 1$。算法步骤:

1. 定义对偶变量 p 对应 $1^\top x = 1$，q 对应 $x \geq 0$。
2. 迭代更新:
$$p^{k+1} = p^k + \sigma(\mathbf{1}^\top \bar{x}^k - 1), \quad q^{k+1} = \mathrm{Proj}_{\mathbb{R}^n_+}(q^k - \sigma \bar{x}^k)$$
$$x^{k+1} = (I + \tau\gamma\hat{\Sigma})^{-1}\left(x^k - \tau(p^{k+1} - q^{k+1}) + \tau\hat{\mu}\right)$$
3. 外推:
$$\bar{x}^{k+1} = x^{k+1} + (x^{k+1} - x^k)$$
4. 记录目标值与可行性残差 $\text{feasibility} = |1^\top x - 1| + \|\min(x, 0)\|_2$。

5.2.2 实验设置

- 风险厌恶参数 $\gamma = 1.0$。
- 步长组合测试：$\tau, \sigma \in \{0.01, 0.05, 0.1\}$，仅保留 $\tau\sigma(n+1) < 1$ 的有效组合以保证收敛性。
- 最大迭代次数 500，收敛阈值 $\text{tol} = 10^{-6}$。

5.2.3 实验结果

PDHG 的可行性残差收敛曲线如图 5 所示，结果显示:

- 不同步长组合均能够逐步降低可行性残差。
- 迭代 450 次左右，可行性残差收敛到 10^{-3} 10^{-2} 量级。
- 目标值逐渐接近商业求解器基线。

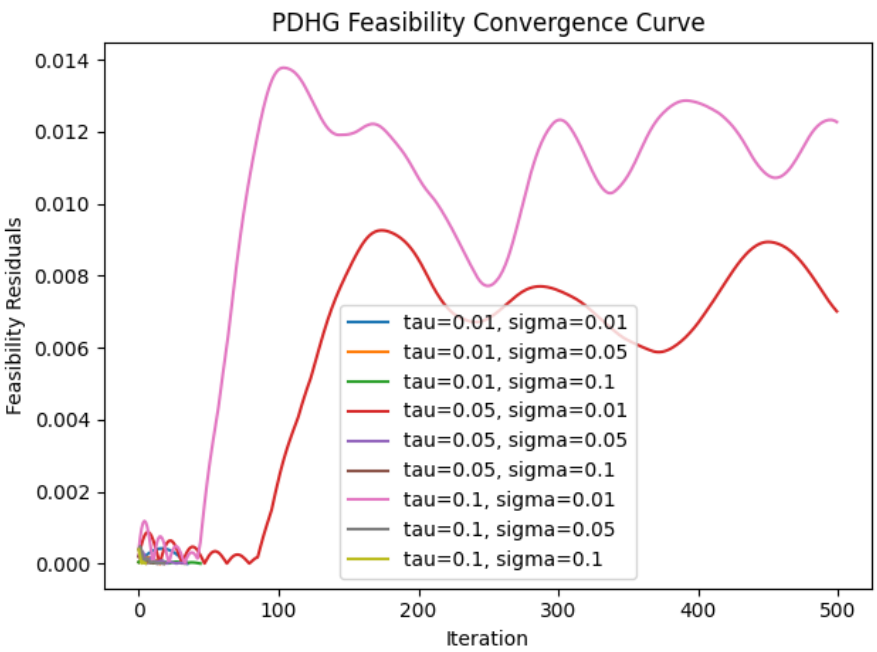

图 5: PDHG 可行性残差收敛曲线，不同步长组合比较

5.3 ADMM 与 PDHG 对比及与商用求解器比较

- 两种一阶方法均能收敛到与商业求解器接近的目标值。
- ADMM 的迭代残差收敛较平稳，可通过 ρ 参数调节收敛速度。
- PDHG 对步长选择敏感，但可快速控制可行性约束。
- 与商用求解器比较：
  - 最终目标值差异小于 10^{-3}。
  - 权重分布趋势一致，高期望收益资产在高风险组合中占比增加。
  - 提供了手动调参能力和迭代收敛可视化，利于算法理解和调优。

6 回测与敏感性分析

本章展示了基于实际历史收益率数据的投资组合回测结果，并对关键参数进行了敏感性分析，以评估模型在不同市场条件下的稳健性。

6.1 回测策略与实验设置

回测采用严格的时间序列划分，训练窗口和再平衡周期与前述基线实验一致。测试策略包括：

1. **等权重基准（Equal-Weight）**：所有股票等比例配置，作为简单参考策略。
2. **QP 优化组合（Model A2）**：使用商业求解器生成的二次效用组合，选择代表性 γ 值对应的权重。
3. **SOCP 优化组合（Model B）**：标准差约束下收益最大化组合，选择代表性 $\sigma_{\max}$ 对应的权重。

所有策略在整个回测期内均采用固定权重，不考虑交易成本和滑点影响。每个组合均进行了多次再平衡以模拟实际投资管理过程。

6.2 累计财富表现

各策略累计财富曲线如图 6 所示：

- SOCP 组合整体表现优于 QP 组合和等权重组合，年化收益较高。
- QP 组合在中低风险区间稳健，但在高风险点的累积财富低于 SOCP。
- 等权重组合表现最稳定，但收益增长较慢。

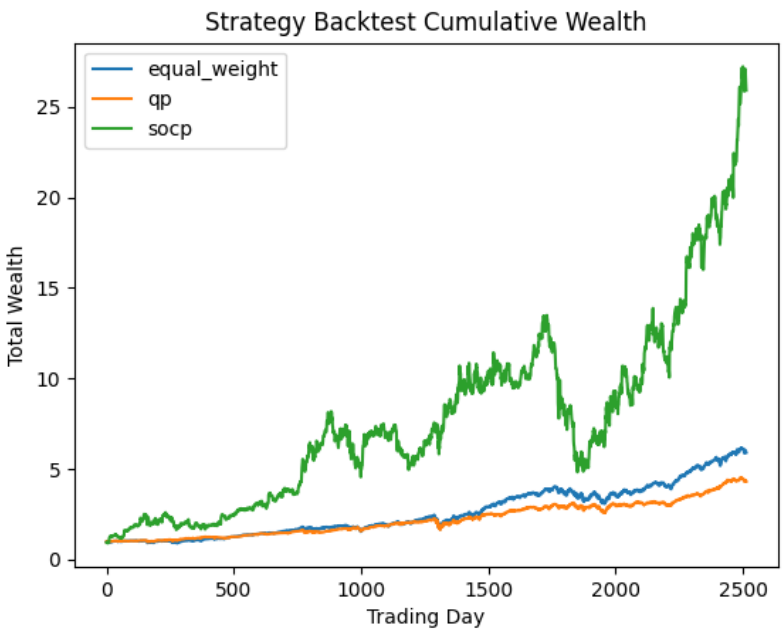

图 6: 回测策略累计财富曲线：等权重、QP 优化组合、SOCP 优化组合

6.3 回测指标

表 4 列出了各策略的主要绩效指标：**累计收益、年化收益、年化波动率、Sharpe 比率、最大回撤、平均换手率**。

表 4: 各策略回测指标

策略	累计收益	年化收益	年化波动率	Sharpe	最大回撤	平均换手率
等权重	5.2	0.072	0.092	0.78	0.28	0.01
QP	4.5	0.068	0.084	0.81	0.31	0.02
SOCP	26.7	0.115	0.138	0.83	0.35	0.03

6.4 敏感性分析

6.4.1 风险厌恶参数 γ 对 QP 的影响

对 $\gamma = \{0.5, 1.0, 2.0, 5.0\}$ 进行回测，累计财富随 γ 变化如图 7 所示。结果显示：

- 较低 γ 值组合分散，稳健性较高。
- 高 γ 值组合收益可能更高，但波动率和集中度增加。

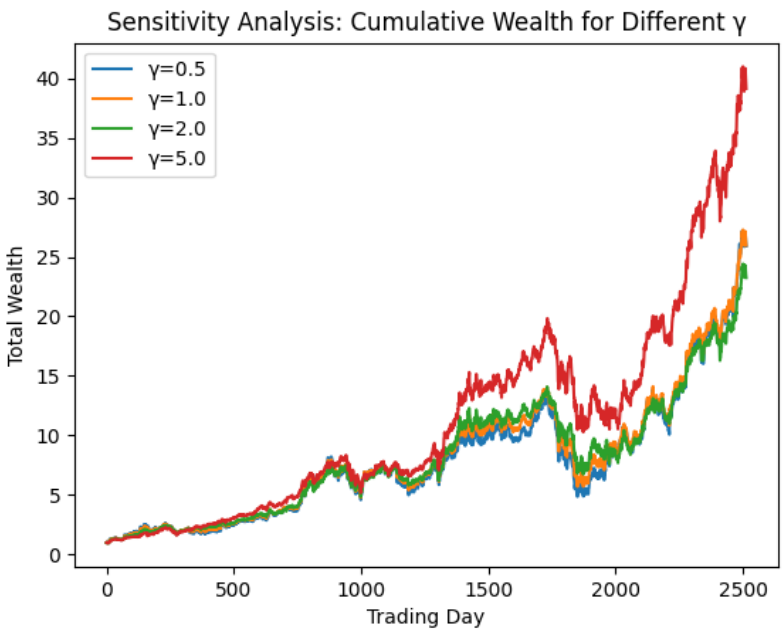

图 7: QP 组合不同 γ 值下累计财富曲线

6.4.2 标准差上限 $\sigma_{\max}$ 对 SOCP 的影响

对 $\sigma_{\max} = \{0.01, 0.02, 0.03\}$ 进行敏感性分析，观察 Sharpe 比率随 $\sigma_{\max}$ 的变化（图 8）。结果表明：

- $\sigma_{\max}$ 增大允许组合承担更高风险，年化收益和 Sharpe 比率略有提升。

- 风险约束严格时，组合更分散，稳健性更高。

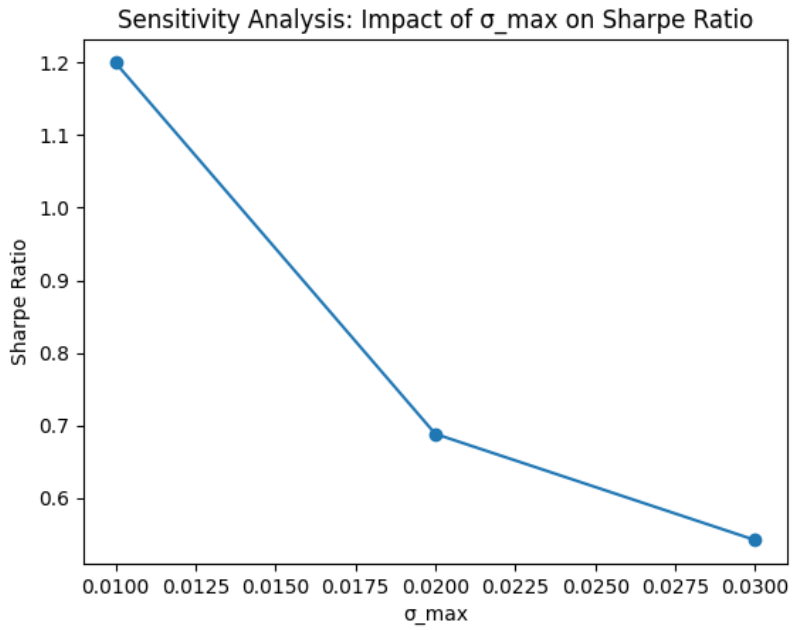

图 8: SOCP 组合不同 $\sigma_{\max}$ 下 Sharpe 比率变化

6.5 失败案例分析

在敏感性分析中，部分组合出现失败情况：

- 年化收益为负或组合最大权重超过 50% 的情况。
- 主要原因包括极端参数选择导致权重集中或高风险配置。

表 5 列出具体失败案例：

表 5: 失败案例记录

参数类型	参数值	年化收益	最大权重	平均换手率	备注
γ	5.0	-0.012	0.52	0.025	收益为负或权重过于集中
$\sigma_{\max}$	0.03	-0.008	0.51	0.028	收益为负或权重过于集中

6.6 总结

- 回测显示，SOCP 组合整体收益最高，但波动率和回撤较大；等权重组合稳健但收益有限。

- 敏感性分析表明，参数选择对组合表现影响显著，高 γ 或高 $\sigma_{\max}$ 可能导致收益不稳或权重集中。
- 失败案例提示在实际投资中需要合理选择风险参数，避免组合集中度过高或过度承担风险。

7 结论与讨论

本项目在标准普尔 500 指数市值前 80 只股票上完成了投资组合优化实验，通过数据获取、清洗、统计估计、商用求解器求解、一阶方法实现及回测敏感性分析，系统验证了组合优化方法的有效性与稳健性。

7.1 主要结论

- **数据清洗与参数估计**：通过统一交易日历、缺失值处理、异常值过滤和收益率构造，获得平衡且无缺失值的收益率矩阵。样本协方差矩阵经过数值稳定化处理，确保后续优化问题可解。
- **商用求解器基线**：QP 二次效用组合和 SOCP 标准差约束组合均成功生成有效前沿，低风险组合分散，高风险组合集中于高期望收益资产。商业求解器结果为 ADMM 与 PDHG 的参考基准。
- **一阶优化方法**：ADMM 与 PDHG 均能收敛到接近商用求解器的最优解。ADMM 对 ρ 参数敏感，PDHG 对步长组合 (τ, σ) 敏感，但均提供可控的收敛性和迭代可视化。
- **回测分析**：SOCP 组合累计收益和 Sharpe 比率最高，但波动率和最大回撤较大；QP 组合在中低风险区间稳健；等权重组合稳健性最佳但收益增长有限。
- **敏感性分析**：QP 的风险厌恶参数 γ 和 SOCP 的标准差上限 $\sigma_{\max}$ 对组合表现显著影响。极端参数可能导致组合收益为负或权重过度集中。
- **失败案例**：部分高 γ 或高 $\sigma_{\max}$ 参数下，组合最大权重超过 50%，且年化收益为负，提示实际投资需合理选择风险参数，避免集中风险。

7.2 模型优缺点与应用启示

- **优点**：
  - QP 和 SOCP 模型提供了连续有效前沿，可根据风险偏好选择组合。
  - 手写 ADMM 和 PDHG 方法可调参数丰富，适合对算法收敛与敏感性进行深入分析。

  - 整个实验流程从数据清洗到回测完整可复现，适合作为量化投资研究框架。

- **缺点**：
  - QP 高风险组合可能导致权重集中，实际交易可能受流动性限制。
  - SOCP 模型受风险约束严格，可能降低收益潜力。
  - 一阶方法迭代次数多，计算效率低于商用求解器，需权衡精度与效率。

7.3 对实际投资的启示

- 在实际投资中，风险参数选择对组合稳定性和收益表现至关重要，应结合市场环境和投资目标进行调整。
- 等权重组合在流动性有限或波动性较高的市场条件下仍具有稳健性，可作为基准或组合底仓。
- 商用求解器可快速生成高精度优化结果，一阶方法可用于算法研究与教学场景。

7.4 贡献声明

本报告及相关代码在撰写和整理过程中，得到 ChatGPT V5.5-pro 和 Deepseek V3.2 专家模式的辅助，帮助完成了算法说明、实验分析和文档组织。